

CURSO DE ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL Y BIGDATA

SISTEMAS DE BIG DATA

## Tarea Evaluable 4.1

Autor: Carlos Sánchez Recio. 07 / 01 / 2025

## ${\rm \acute{I}ndice}$

1.	Crea la tabla vehículos en HBase	1
2.	Inserta mediante órdenes put las tres primeras filas de la tabla	1
3.	Haz un archivo CSV con las 3 últimas filas y cárgalo en la tabla	2
4.	Muestra todos los datos de la fila 4 con un get	4
5.	Muestra los datos de información general de la tabla con un scan	4
6.	Muestra todos los datos de los vehículos con estado bo	5
7.	Muestra los datos de los propietarios de los vehículos de Mallorca	6
8.	Muestra la información general de los vehículos que sean posteriores a 2017 (in-	
	cluido) con menos de 50000 km	6
9.	Modifica la fila 2 y ponle el teléfono 656123321	6
10.	Borra todos los datos en la fila 5	6
11.	Crea una tabla externa en Hive vinculada a la tabla vehículos de HBase	7
12.	Haz una consulta en HiveQL que devuelva los datos de información general de los	
	vehículos de Palma.	8
13.	Haz una consulta en Impala que devuelva todos los datos de los 3 vehículos más	
	caros	8
14.	Haz una consulta en HiveQL que agrupe a los vehículos por estado y muestre la	
	media de km de cada estado	9
15.	Haz una consulta en Impala que agrupe a los vehículos por isla y muestre el	
	número de vehículos de cada isla	9

En esta tarea vamos a trabajar con HBase. Tenemos una tabla vehicles para gestionar un sistema de venta de vehículos de segunda mano .

Esta tabla muestra los datos que debe contener la tabla vehicles:

clau	info_general				conservacio			propietari				ubicacio			
	marca	model	matricula	preu	any	km	estat	nif	nom	telefon	mail	ciutat	illa	longitud	latitud
1	Toyota	Corolla	1234ABC	12000	2015	120000	bo	12345678A	Joan Martínez	623456789	joan.martinez@email.com	Palma	Mallorca	2.650160	39.569600
2	Ford	Focus	5678DEF	15500	2018	55000	molt bo	87654321B	Ana García		ana.garcia@email.com	Palma	Mallorca		
3	Honda	Civic	9012GHI	18000	2020	20000	bo	11223344C	David López	655123456		Eivissa	Eivissa	1.452850	38.916280
4	Mercedes-Benz	A-Class	3456JKL	30000	2019	40000	bo	22334455D	Maria Sánchez	672345678		Manacor	Mallorca	3.703790	40.416780
5	BMW	X5	7890JKL	25000	2017	70000	bo	33445566E	Jordi Pérez		jordi.perez@email.com	Ciutadella	Menorca	0.376288	39.469907
6	Audi	A4	1122XYZ	20000	2016	80000	molt bo	44556677F	Laura Martín	687654321	laura.martin@email.com	Maó	Menorca		

## Tienes que seguir los siguientes pasos:

1. Crea la tabla vehículos en HBase.

```
create 'vehicles', 'info_general', 'conservacio', 'propietari', 'ubicacio'
```

```
| hbase(main):058:0* create 'vehicles', 'info_general', 'conservacio', 'propietari', 'ubicacio'
0 row(s) in 1.3150 seconds
| => Hbase::Table - vehicles
```

2. Inserta mediante órdenes put las tres primeras filas de la tabla.

```
put 'vehicles', '1', 'info_general:marca', 'Toyota'
   put 'vehicles', '1', 'info_general:model', 'Corolla'
   put 'vehicles', '1', 'info_general:matricula', '1234ABC'
   put 'vehicles', '1', 'info_general:preu', '12000'
   put 'vehicles', '1', 'conservacio:any', '2015'
   put 'vehicles', '1', 'conservacio:km', '120000'
   put 'vehicles', '1', 'conservacio:estat', 'bo'
   put 'vehicles', '1', 'propietari:nif', '12345678A'
   put 'vehicles', '1', 'propietari:nom', 'Joan Mart nez'
   put 'vehicles', '1', 'propietari:telefon', '623456789'
   put 'vehicles', '1', 'propietari:mail', 'joan.martinez@email.com'
  put 'vehicles', '1', 'ubicacio:ciutat', 'Palma'
  put 'vehicles', '1', 'ubicacio:illa', 'Mallorca'
   put 'vehicles', '1', 'ubicacio:longitud', '2.650160'
  put 'vehicles', '1', 'ubicacio:latitud', '39.569600'
  put 'vehicles', '2', 'info_general:marca', 'Ford'
17
   put 'vehicles', '2', 'info_general:model', 'Focus'
  put 'vehicles', '2', 'info_general:matricula', '5678DEF'
put 'vehicles', '2', 'info_general:preu', '15500'
   put 'vehicles', '2', 'conservacio:any', '2018'
   put 'vehicles', '2', 'conservacio:km', '55000'
   put 'vehicles', '2', 'conservacio:estat', 'molt bo'
   put 'vehicles', '2', 'propietari:nif', '87654321B'
   put 'vehicles', '2', 'propietari:nom', 'Ana Garc a'
   put 'vehicles', '2', 'propietari:telefon', ''
   put 'vehicles', '2', 'propietari:mail', 'ana.garcia@email.com'
  put 'vehicles', '2', 'ubicacio:ciutat', 'Palma'
```

```
put 'vehicles', '2', 'ubicacio:illa', 'Mallorca'
29
30
   put 'vehicles', '3', 'info_general:marca', 'Honda'
31
   put 'vehicles', '3', 'info_general:model', 'Civic'
32
   put 'vehicles', '3', 'info_general:matricula', '9012GHI'
33
   put 'vehicles', '3', 'info_general:preu', '18000'
34
   put 'vehicles', '3', 'conservacio:any', '2020' put 'vehicles', '3', 'conservacio:km', '20000'
   put 'vehicles', '3', 'conservacio:estat', 'bo'
   put 'vehicles', '3', 'propietari:nif', '11223344C'
   put 'vehicles', '3', 'propietari:nom', 'David L pez'
   put 'vehicles', '3', 'propietari:telefon', '655123456'
40
   put 'vehicles', '3', 'ubicacio:ciutat', 'Eivissa'
41
   put 'vehicles', '3', 'ubicacio:illa', 'Eivissa'
42
   put 'vehicles', '3', 'ubicacio:longitud', '1.452850'
43
   put 'vehicles', '3', 'ubicacio:latitud', '38.916280'
44
   # test
47 | scan 'vehicles'
```

```
hbase(main):060:0> put 'vehicles', '1', 'info_general:model', 'Corolla'
0 row(s) in 0.0440 seconds
hbase(main):061:0> put 'vehicles', '1', 'info_general:matricula', '1234ABC'
0 row(s) in 0.1220 seconds
hbase(main):062:0> put 'vehicles', '1', 'info_general:preu', '12000'
0 row(s) in 0.2370 seconds
hbase(main):063:0> put 'vehicles', '1', 'conservacio:any', '2015'
hbase(main):064:0> put 'vehicles', '1', 'conservacio:km', '120000'
 row(s) in 0.0160 seconds
hbase(main):065:0> put 'vehicles', '1', 'conservacio:estat', 'bo'
0 row(s) in 0.0140 seconds
hbase(main):066:0> put 'vehicles', '1', 'propietari:nif', '12345678A'
0 row(s) in 0.0050 seconds
hbase(main):067:0> put 'vehicles', '1', 'propietari:nom', 'Joan Mart?nez'
0 row(s) in 0.0040 seconds
hbase(main):068:0> put 'vehicles', '1', 'propietari:telefon', '623456789'
0 row(s) in 0.0040 seconds
hbase(main):069:0> put 'vehicles', '1', 'propietari:mail', 'joan.martinez@email.com'
 row(s) in 0.0110 seconds
hbase(main):070:0> put 'vehicles', '1', 'ubicacio:ciutat', 'Palma'
0 row(s) in 0.0480 seconds
hbase(main):071:0> put 'vehicles', '1', 'ubicacio:illa', 'Mallorca'
 row(s) in 0.0040 seconds
hbase(main):072:0> put 'vehicles', '1', 'ubicacio:longitud', '2.650160'
0 row(s) in 0.0050 seconds
hbase(main):073:0> put 'vehicles', '1', 'ubicacio:latitud', '39.569600'
0 row(s) in 0.0080 seconds
hbase(main):074:0>
 base(main):075:0* put 'vehicles', '2', 'info_general:marca', 'Ford'
 row(s) in 0.1280 seconds
hbase(main):076:0> put 'vehicles', '2', 'info_general:model', 'Focus'
 row(s) in 0.0070 seconds
hbase(main):077:0> put 'vehicles', '2', 'info_general:matricula', '5678DEF'
 row(s) in 0.0050 seconds
hbase(main):078:0> put 'vehicles', '2', 'info_general:preu', '15500'
0 row(s) in 0.0040 seconds
hbase(main):079:0> put 'vehicles', '2', 'conservacio:any', '2018'
0 row(s) in 0.0040 seconds
```

3. Haz un archivo CSV con las 3 últimas filas y cárgalo en la tabla.

```
hdfs dfs -mkdir vehicles
hdfs dfs -put vehicles.csv vehicles/
cat vehicles.csv # Just to test if needed
hdfs dfs -ls /user/cloudera/vehicles # Just to test if needed
hbase org.apache.hadoop.hbase.mapreduce.ImportTsv \
-Dimporttsv.columns="HBASE_ROW_KEY,info_general:marca,info_general:model,
info_general:matricula,info_general:preu,conservacio:any,conservacio:km,
conservacio:estat,propietari:nif,propietari:nom,propietari:telefon,propietari:mail,
ubicacio:ciutat,ubicacio:illa,ubicacio:longitud,ubicacio:latitud" \
-Dimporttsv.separator=',' vehicles /user/cloudera/vehicles/vehicles.csv

# test
scan 'vehicles'
```

```
column-ubicacio:latitud, timestamp=1736274013182, value=38.916280
column-ubicacio:longitud, timestamp=1736274012637, value=1.462880
column-conservacio:any, timestamp=1736274012637, value=30.91
column-conservacio:extat, timestamp=173627410148, value=3019
column-conservacio:extat, timestamp=1736274109148, value=40800
column-info_generalimatricula, timestamp=17362741409148, value=40800
column-info_generalimatricula, timestamp=17362741409148, value=40800
column-info_generalimatricula, timestamp=17362741409148, value=40800
column-projetariinali, timestamp=17362741409148, value=30800
column-projetariinini, timestamp=17362741409148, value=30800
column-projetariininin, timestamp=17362741409148, value=22334455D
column-projetariinin, my timestamp=17362741409148, value=472345678
column-ubicacio:alian, timestamp=17362741409148, value=672345678
column-ubicacio:alian, timestamp=17362741409148, value=8612678
column-ubicacio:alian, timestamp=17362741409148, value=8612678
column-ubicacio:alian, timestamp=17362741409148, value=861278
column-ubicacio:alian, timestamp=17362741409148, value=872345678
column-ubicacio:alian, timestamp=17362741409148, value=872345678
column-ubicacio:alian, timestamp=17362741409148, value=872345678
column-conservacio:estat, timestamp=17362741409148, value=8723678
column-info_generalimarical, timestamp=17362741409148, value=8800
column-projetariininf, timestamp=17362741409148, value=8800
column-projetariininf, timestamp=17362741409148, value=9600
column-projetariininf, timestamp=17362741409148, value=36600
column-projetariininf, timestamp=17362741409148, value=8800
column-projetariininin, timestamp=17362741409148, value=8800
column-projetariinininin, timestamp=17362741409148, val
```

4. Muestra todos los datos de la fila 4 con un get.

```
get 'vehicles', '4'
```

```
hbase(main):002:0> get 'vehicles', '4'
                               CELL
COLUMN
conservacio:any
                                timestamp=1736274149148, value=2019
                               timestamp=1736274149148, value=bo
conservacio:estat
conservacio:km
                               timestamp=1736274149148, value=40000
info_general:marca
                               timestamp=1736274149148, value=Mercedes-Benz
                               timestamp=1736274149148, value=3456JKL
info_general:matricula
info_general:model
                               timestamp=1736274149148, value=A-Class
info_general:preu
                               timestamp=1736274149148, value=30000
                               timestamp=1736274149148, value=
propietari:mail
propietari:nif
                                timestamp=1736274149148, value=22334455D
propietari:nom
                               timestamp=1736274149148, value=Maria S\xC3\xA1nchez
propietari:telefon
                                timestamp=1736274149148, value=672345678
ubicacio:ciutat
                                timestamp=1736274149148, value=Manacor
ubicacio:illa
                                timestamp=1736274149148, value=Mallorca
ubicacio:latitud
                                timestamp=1736274149148, value=40.416780
ubicacio:longitud
                                timestamp=1736274149148, value=3.703790
5 row(s) in 0.0210 seconds
```

5. Muestra los datos de información general de la tabla con un scan.

```
scan 'vehicles', {COLUMNS => 'info_general'}
```

6. Muestra todos los datos de los vehículos con estado bo.

```
scan 'vehicles', {FILTER => "SingleColumnValueFilter('conservacio', 'estat', =, 'binary:bo')"}
```

```
hbase(main):004:00 scan 'vehicles', (FILTER => 'SingleColumnValueFilter('conservacio', 'estat', =, 'binary:bo')')
ROW

COLUMN-CELL

column-conservacio:any, timestamp=776076413563, value=2015

column-conservacio:any, timestamp=776076413563, value=2015

column-info_general imarce, timestamp=1736274013583, value=109016

column-info_general imarce, timestamp=173627401383, value=109016

column-info_general imarce, timestamp=173627401383, value=109016

column-info_general imarce, timestamp=173627401383, value=203406

column-info_general imarce, timestamp=173627401387, value=028406

column-propietari imati, timestamp=1736274013687, value=30an.martim=208061

column-propietari imati, timestamp=173627401308, value=joan.martim=208061

column-propietari imati, timestamp=173627401308, value=joan.martim=208061

column-propietari imaticle imatemp=173627401308, value=30an.martim=208061

column-bicacio:illat, timestamp=1736274012084, value=90806

column-bicacio:illat, timestamp=1736274012108, value=90806

column-bicacio:illat, timestamp=1736274012108, value=90806

column-bicacio:illat, timestamp=1736274012108, value=90806

column-bicacio:illat, timestamp=1736274012407, value=90806

column-bicacio:illat, timestamp=1736274012508, value=65512365

column-bicacio:illat, timestamp=1736274012508, value=65512365

column-bicacio:illat, timestamp=1736274012508, value=65512365

column-bicacio:illat, timestamp=1736274012508, value=65512666

column-bicacio:illat, timestamp=1736274012508, value=65512666

column-bicacio:illat, timestamp=1736274012508, value=65612666

column-bicacio:illat, timestamp=1736274012508, value=665614

column-bicacio:illat, timestamp=1736274012508, value=665614

column-bicacio:illat, timestamp=1736274012508, value=666741

c
```

7. Muestra los datos de los propietarios de los vehículos de Mallorca.

```
# Selected manually due to version incompatibilities scan 'vehicles', {FILTER => "RowFilter(=,'binary:1') OR RowFilter(=,'binary:2') OR RowFilter(=,'binary:4')", COLUMNS => ['propietari']}
```

8. Muestra la información general de los vehículos que sean posteriores a 2017 (incluido) con menos de 50000 km.

```
# Selected manually due to version incompatibilities scan 'vehicles', {FILTER => "RowFilter(=,'binary:3') OR RowFilter(=,'binary:4')", COLUMNS => ['info_general']}
```

```
hbase(main):008:0> scan 'vehicles', {FILTER => "RowFilter(=, 'binary:3') OR RowFilter(=, 'binary:4')*, COLUMNS => ['info_ge neral']}
ROW COLUMN+CELL
3 column=info_general:marca, timestamp=1736274012378, value=Honda
3 column=info_general:matricula, timestamp=1736274012378, value=00120HI
3 column=info_general:model, timestamp=1736274012395, value=0120HI
3 column=info_general:prou, tinestamp=1736274012395, value=Evicic
4 column=info_general:marca, timestamp=173627401240, value=Mercedes=Benz
4 column=info_general:marca, timestamp=1736274149148, value=46546KL
4 column=info_general:matricula, timestamp=1736274149148, value=AcClass
column=info_general:marca, timestamp=1736274149148, value=30000
```

9. Modifica la fila 2 y ponle el teléfono 656123321.

```
put 'vehicles', '2', 'propietari:telefon', '656123321'
get 'vehicles', '2' # Check
```

```
[hbase(main):002:0> put 'vehicles', '2', 'propietari:telefon', '656123321'
0 row(s) in 0.1230 seconds
[hbase(main):003:0> get 'vehicles', '2'
COLUMN
                                 CELL
 conservacio:any
                                 timestamp=1736274012245, value=2018
                                 timestamp=1736274012271, value=molt bo
 conservacio:estat
 conservacio:km
                                 timestamp=1736274012258, value=55000
                                 timestamp=1736274012189, value=Ford
 info_general:marca
                                 timestamp=1736274012218, value=5678DEF
 info_general:matricula
                                 timestamp=1736274012204, value=Focus
 info_general:model
 info_general:preu
                                 timestamp=1736274012231, value=15500
 propietari:mail
                                 timestamp=1736274012331, value=ana.garcia@email.com
 propietari:nif
                                 {\tt timestamp=1736274012287,\ value=87654321B}
                                 timestamp = 1736274012302, \ value = Ana \ Garc \ xC3 \ xADa
 propietari:nom
                                 timestamp=1736276748645, value=656123321
 propietari:telefon
                                 timestamp=1736274012344, value=Palma
 ubicacio:ciutat
 ubicacio:illa
                                 timestamp=1736274012360, value=Mallorca
13 row(s) in 0.0230 seconds
```

10. Borra todos los datos en la fila 5.

```
deleteall 'vehicles', '5'
scan 'vehicles' # Check
```

```
column=info_general:model, timestamp=1736274149148, value=A-Class
column=propietari:mail, timestamp=1736274149148, value=General:mail, timestamp=1736274149148, value=Maria S\xC3\x
column=propietari:nif, timestamp=1736274149148, value=Maria S\xC3\x
column=propietari:nom, timestamp=1736274149148, value=Maria S\xC3\x
column=propietari:telefon, timestamp=1736274149148, value=Maria S\xC3\x
column=ubicacio:ciutat, timestamp=1736274149148, value=Manacor
column=ubicacio:latitud, timestamp=1736274149148, value=Mallorca
column=ubicacio:latitud, timestamp=1736274149148, value=A-6.16780
column=conservacio:any, timestamp=1736274149148, value=2016
column=conservacio:estat, timestamp=1736274149148, value=B0000
column=info_general:marca, timestamp=1736274149148, value=B0000
column=info_general:matricula, timestamp=1736274149148, value=A-6
column=info_general:model, timestamp=1736274149148, value=A-6
column=propietari:mif, timestamp=1736274149148, value=A-6
column=propietari:nif, timestamp=1736274149148, value=Laura Mart\xC
column=propietari:nom, timestamp=1736274149148, value=Laura Mart\xC
column=propietari:telefon, timestamp=1736274149148, value=Laura Mart\xC
column=propietari:telefon, timestamp=1736274149148, value=Ba0000
column=propietari:telefon, timest
```

11. Crea una tabla externa en Hive vinculada a la tabla vehículos de HBase.

```
CREATE EXTERNAL TABLE hbase_vehicles (
       key bigint,
2
       info_general_marca string,
       info_general_model string,
       info_general_matricula string,
       info_general_preu decimal(10,2),
6
       conservacio_any int ,
       conservacio_km bigint,
       conservacio_estat string,
9
       propietari_nif string,
10
       propietari_nom string,
11
       propietari_telefon string,
12
       propietari_mail string,
13
       ubicacio_ciutat string,
       ubicacio_illa string,
15
       ubicacio_longitud decimal(10,7),
16
       ubicacio_latitud decimal(10,7)
17
18
   STORED BY 'org.apache.hadoop.hive.hbase.HBaseStorageHandler'
19
   WITH SERDEPROPERTIES (
20
       'hbase.columns.mapping' = ':key,info_general:marca,info_general:model,info_general:
21
           matricula, info_general:preu, conservacio:any, conservacio:km, conservacio:estat,
22
           propietari:nif,propietari:nom,propietari:telefon,propietari:mail,ubicacio:ciutat
            ,ubicacio:illa,ubicacio:longitud,ubicacio:latitud'
25
   TBLPROPERTIES (
26
       'hbase.table.name' = 'vehicles'
27
   );
28
```

```
## Hive ** Add a name... Add a description...

## Add a name... Add a name... Add a description...

## Add a name... Add a description...

## Add a name... Add a description...

## Add a name... Add a name... Add a description...

## Add a name... Add a name... Add a description...

## Add a name... Add a name... Add a description...

## Add a name... Add a name... Add a name... Add a name... Add a name..
```

12. Haz una consulta en HiveQL que devuelva los datos de información general de los vehículos de Palma.

```
SELECT info_general_marca,info_general_model,
info_general_matricula,info_general_preu

FROM hbase_vehicles
WHERE ubicacio_ciutat = "Palma";
```



13. Haz una consulta en Impala que devuelva todos los datos de los 3 vehículos más caros.

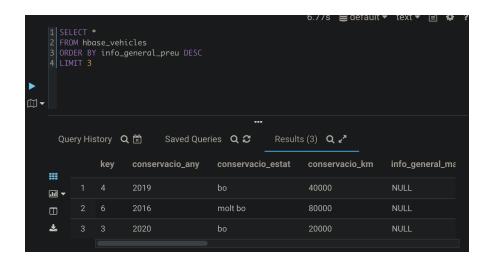
```
INVALIDATE METADATA;

SELECT *

FROM hbase_vehicles

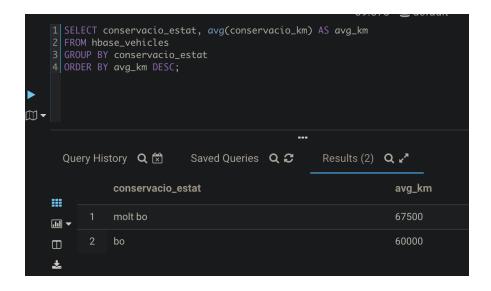
ORDER BY info_general_preu DESC

LIMIT 3;
```



14. Haz una consulta en HiveQL que agrupe a los vehículos por estado y muestre la media de km de cada estado.

```
SELECT conservacio_estat, avg(conservacio_km) AS avg_km
FROM hbase_vehicles
GROUP BY conservacio_estat
ORDER BY avg_km DESC;
```



15. Haz una consulta en Impala que agrupe a los vehículos por isla y muestre el número de vehículos de cada isla.

```
INVALIDATE METADATA;

SELECT COUNT(*) AS coches, ubicacio_illa

FROM hbase_vehicles

GROUP BY ubicacio_illa;
```

